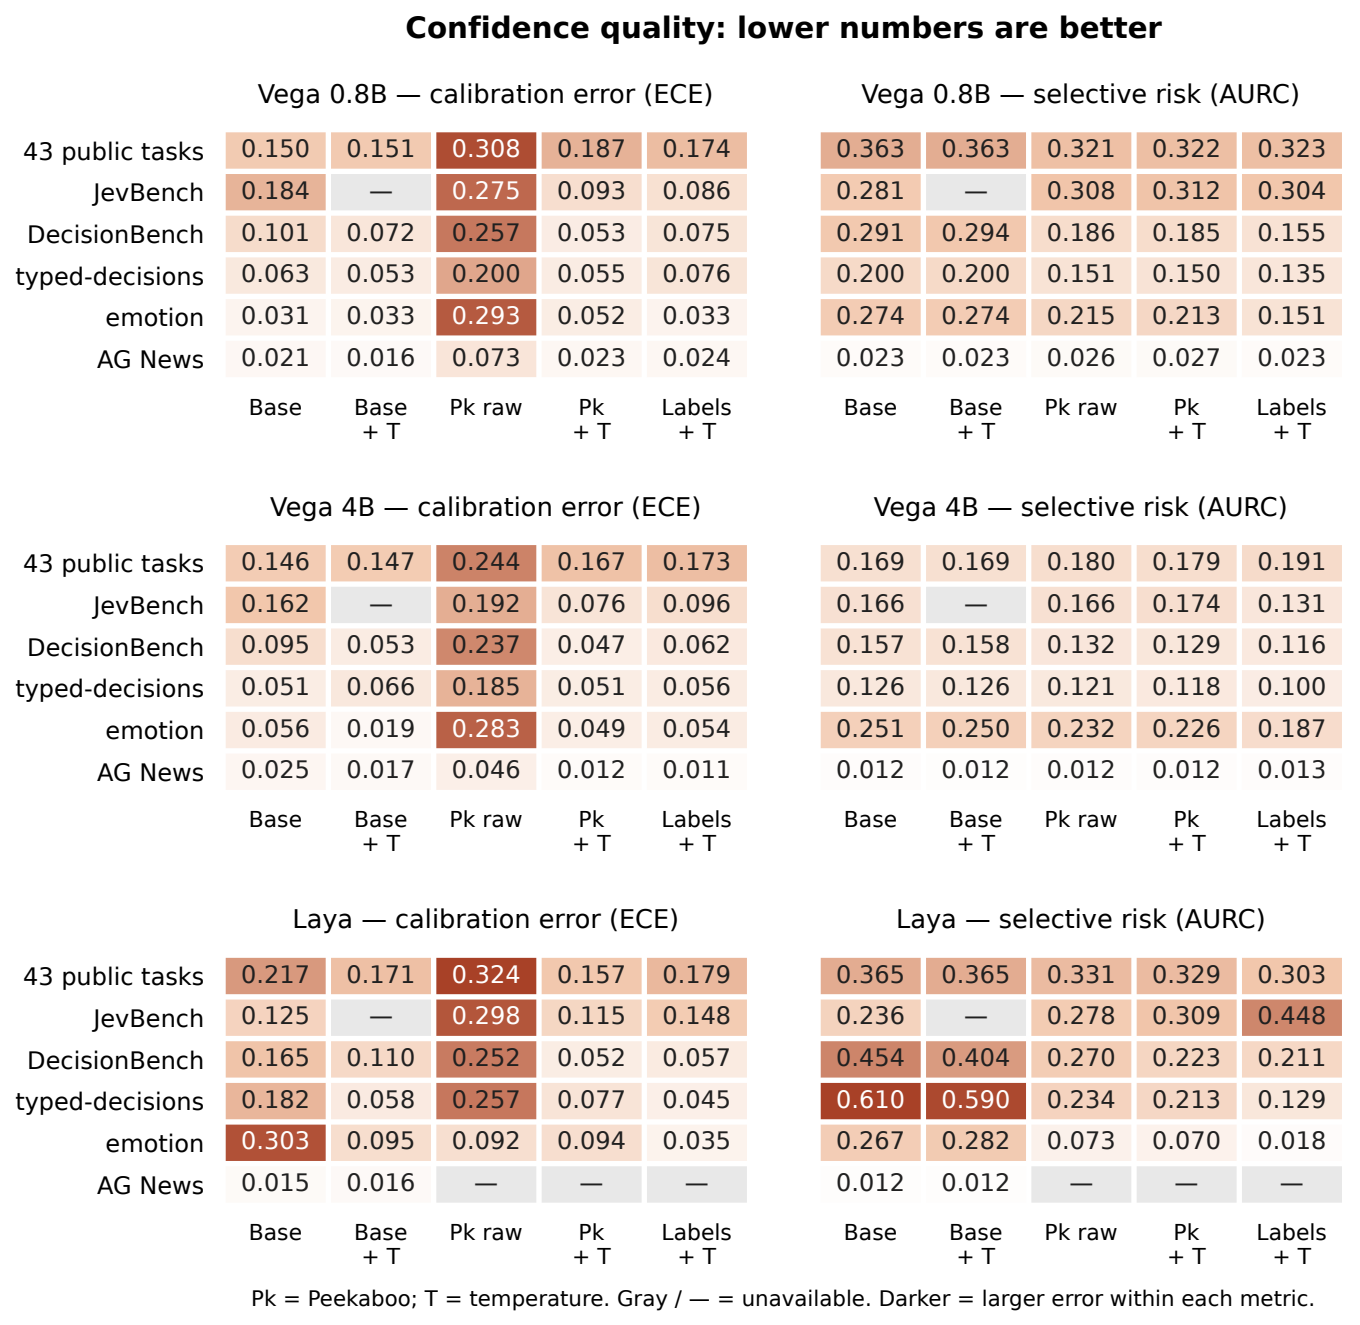
Confidence quality: lower numbers are better
Vega 0.8B — calibration error (ECE)
43 public tasks 0.150 0.151 0.308 0.187 0.174
JevBench 0.184 — 0.275 0.093 0.086
DecisionBench 0.101 0.072 0.257 0.053 0.075
typed-decisions 0.063 0.053 0.200 0.055 0.076
emotion 0.031 0.033 0.293 0.052 0.033
AG News 0.021 0.016 0.073 0.023 0.024
Base
Base + T
Pk raw
Pk + T
Labels + T
Vega 0.8B — selective risk (AURC)
0.363 0.363 0.321 0.322 0.323
0.281 — 0.308 0.312 0.304
0.291 0.294 0.186 0.185 0.155
0.200 0.200 0.151 0.150 0.135
0.274 0.274 0.215 0.213 0.151
0.023 0.023 0.026 0.027 0.023
Base
Base + T
Pk raw
Pk + T
Labels + T
Vega 4B — calibration error (ECE)
43 public tasks 0.146 0.147 0.244 0.167 0.173
JevBench 0.162 — 0.192 0.076 0.096
DecisionBench 0.095 0.053 0.237 0.047 0.062
typed-decisions 0.051 0.066 0.185 0.051 0.056
emotion 0.056 0.019 0.283 0.049 0.054
AG News 0.025 0.017 0.046 0.012 0.011
Base
Base + T
Pk raw
Pk + T
Labels + T
Vega 4B — selective risk (AURC)
0.169 0.169 0.180 0.179 0.191
0.166 — 0.166 0.174 0.131
0.157 0.158 0.132 0.129 0.116
0.126 0.126 0.121 0.118 0.100
0.251 0.250 0.232 0.226 0.187
0.012 0.012 0.012 0.012 0.013
Base
Base + T
Pk raw
Pk + T
Labels + T
Laya — calibration error (ECE)
43 public tasks 0.217 0.171 0.324 0.157 0.179
JevBench 0.125 — 0.298 0.115 0.148
DecisionBench 0.165 0.110 0.252 0.052 0.057
typed-decisions 0.182 0.058 0.257 0.077 0.045
emotion 0.303 0.095 0.092 0.094 0.035
AG News 0.015 0.016 — — —
Base
Base + T
Pk raw
Pk + T
Labels + T
Laya — selective risk (AURC)
0.365 0.365 0.331 0.329 0.303
0.236 — 0.278 0.309 0.448
0.454 0.404 0.270 0.223 0.211
0.610 0.590 0.234 0.213 0.129
0.267 0.282 0.073 0.070 0.018
0.012 0.012 — — —
Base
Base + T
Pk raw
Pk + T
Labels + T
Pk = Peekaboo; T = temperature. Gray / — = unavailable. Darker = larger error within each metric.